# TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

**Başvuru formunun Arial 9 yazı tipinde, her bir konu başlığı altında verilen açıklamalar göz önünde bulundurularak hazırlanması ve ekler hariç toplam 20 sayfayı geçmemesi beklenir (Alt sınır bulunmamaktadır). Değerlendirme araştırma önerisinin bilimsel niteliği, yöntemi, proje yönetimi ve yaygın etkisi başlıkları üzerinden yapılacaktır.**

## ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

## 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI
## ARAŞTIRMA ÖNERİSİ FORMU

### A. GENEL BİLGİLER

| |
|---|
| **Başvuru Sahibinin Adı Soyadı:** Beyza Yörük |
| **Araştırma Önerisinin Başlığı:** Düzensiz (Non-Globular) MYC ve CTNNB1 Onkoproteinleri için Makine Öğrenmesi Tabanlı Yeniden Konumlandırılmış İlaç Keşfi |
| **Danışmanın Adı Soyadı:** Doç.Dr.Tuğba ÖNAL SÜZEK |
| **Araştırmanın Yürütüleceği Kurum/Kuruluş:** Muğla Sıtkı Koçman Üniversitesi |

### ÖZET

Araştırma önerisi özetinin (1) bilimsel nitelik; (2) yöntem; (3) proje yönetimi ve (4) yaygın etki hakkında bilgileri kapsaması beklenir. Bu bölümün en son yazılması önerilir.


**Özet**

Kanser tedavisinde kritik rol oynayan MYC ve CTNNB1 onkoproteinleri, 'ilaçlanamaz' (undruggable) kabul edilmektedir. Bunun temel nedeni, geleneksel ilaç keşfine uygun stabil cepleri olmayan düzensiz (IDP) yapılarıdır. Bu proje, bu zorlu hedefler için literatürdeki metodolojik boşluğu doldurarak makine öğrenmesi (ML) tabanlı bir ilaç yeniden konumlandırma stratejisi geliştirmeyi amaçlamaktadır. Projenin yöntemi; ChEMBL gibi veri tabanlarından toplanan biyoaktivite verileriyle (≥850 aktif molekül) Random Forest ve Graph Neural Network (GNN) gibi ML modellerini eğitmeye dayanmaktadır. Bu modeller, MYC-MAX ve β-katenin-TCF4 protein-molekül etkileşimi potansiyeli olan adayları PubChem veritabanından taramak için kullanılacaktır. En iyi 'hit' adaylar, moleküler kenetlenme (docking) ve 100 ns moleküler dinamik (MD) simülasyonları ile hesaplamalı olarak doğrulanacaktır. 12 ay sürecek olan proje; veri toplama, model geliştirme, sanal tarama, simülasyon ve raporlama olmak üzere beş iş paketi (İP) altında yönetilecektir. Projenin temel yaygın etkisi, 'ilaçlanamaz' hedeflere yönelik yenilikçi bir hesaplamalı yöntem sunarak bilimsel literatüre katkı sağlamak ve ileri deneysel çalışmalara temel oluşturacak bir aday molekül listesi oluşturmaktır.



**Anahtar Kelimeler:** Makine Öğrenmesi, İlaç Yeniden Konumlandırma, Düzensiz Proteinler, MYC, CTNNB1


### 1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

#### 1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Araştırma önerisinde ele alınan konunun kapsamı, sınırları ve önemi ortaya konulur. Araştırma önerisi kapsamında yapılacak çalışmalarla literatürdeki hangi eksikliğin nasıl giderileceği veya hangi soruna nasıl bir çözüm getirileceği ilgili literatüre atıfla açıklanarak araştırma önerisinin bilimsel niteliği ortaya konulur. Araştırma sorusu ve varsa hipotez(ler)i tanımlanır.
Projenin konusu, 12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi'nde yer alan kritik teknoloji alanları ile öncelikli Ar-Ge ve yenilik konuları ile ilişkili ise, ilişkilendirilme sebebi ve ilgili alana sağlayacağı yararlar açıklanmalıdır.

Kanser, dünya genelinde en önemli sağlık sorunlarından biri olup, moleküler tedavi hedeflerinin belirlenmesi kritik öneme sahiptir. MYC ve CTNNB1 (β-katenin) onkoproteinleri, birçok kanser türünde aşırı eksprese edilmekte veya mutasyona uğramaktadır. MYC, hücre proliferasyonu ve metabolizmasında merkezi rol oynayan bir transkripsiyon faktörüdür ve birçok kanserde aşırı aktivasyonu gözlemlenmektedir [4]. CTNNB1 geni tarafından kodlanan β-katenin proteini ise Wnt/β-katenin sinyal yolunun anahtar efektörüdür; kolorektal kanserlerin %81,9'unda APC mutasyonları, %48'inde ise doğrudan CTNNB1 mutasyonları bulunmaktadır [1]. Bu yüksek mutasyon oranları, her iki proteinin de kanser tedavisinde kritik hedefler olduğunu göstermektedir.

Ancak MYC ve β-katenin, intrinsik olarak düzensiz protein bölgeleri (IDP) içermeleri nedeniyle "undruggable" (ilaçlanamaz) olarak kabul edilmektedir. Bu düzensiz yapıları, derin bağlanma ceplerine sahip klasik ilaç hedeflerinden farklı kılmakta ve geleneksel yapı-bazlı ilaç tasarım yöntemlerinin başarısız olmasına neden olmaktadır [1]. Bu durum, IDP'lerin dinamik doğasının klasik "anahtar-kilit" modeline dayalı yöntemlerle temsil edilememesi ve bu proteinler için deneysel olarak doğrulanmış etkileşim verilerinin yetersiz olmasından kaynaklanmaktadır.

Literatürde IDP onkoproteinler (ör. MYC, CTNNB1, p53, KRAS) üzerinde gerçekleştirilen çalışmaların büyük çoğunluğu **in vitro, in vivo veya moleküler dinamik (MD)** tabanlı yapısal karakterizasyonlara odaklanmaktadır. Öte yandan, makine öğrenmesi tabanlı ligand bağlanma tahmini alanında yapılan araştırmalar son derece sınırlıdır. Son yıllarda yayınlanan çalışmalar, IDP-hedefli ilaç tasarımında eğitim verisi eksikliğinin hala büyük bir darboğaz oluşturduğunu [12, 14] ve rasyonel IDP-ilaç keşfi yöntemlerinin kritik derecede geliştirilmesi gerektiğini [13, 14] vurgulamaktadır.

**Araştırma Sorusu:** Düzensiz yapıya sahip MYC ve CTNNB1 onkoproteinlerini hedefleyebilecek potansiyel inhibitörler, biyoaktivite verilerine dayalı makine öğrenmesi modelleri kullanılarak tahmin edilebilir mi?

**Hipotez:** Büyük ölçekli biyoaktivite verilerinden öğrenen makine öğrenmesi modelleri, protein konformasyonel heterojenliğinden bağımsız olarak, düzensiz proteinler için etkili bağlayıcıları tanımlayabilir.

Bu proje, literatürdeki kritik boşluğu doldurmayı hedefleyerek, IDP'lerin konformasyonel çeşitliliğini hesaba katmaksızın biyoaktivite tabanlı yapay zeka modelleriyle ligand bağlanma potansiyelini doğrudan tahmin eden öncü bir yaklaşım sunmaktadır. Böylece, MYC ve β-katenin gibi "undruggable" kabul edilen düzensiz proteinler için makine öğrenmesi odaklı ligand tanıma stratejilerinin uygulanabilirliğini göstermeyi ve bu alandaki metodolojik eksikliği gidermeyi amaçlamaktadır. Lehrich ve arkadaşlarının β-katenin [5] ve Singh ve arkadaşlarının MYC proteinini hedefleyen çalışmaları [9, 10], bu proteinlerin ilaç hedefi olarak kullanılabileceğini deneysel olarak doğrulamıştır.

12. Kalkınma Planı ve 2030 Sanayi ve Teknoloji Stratejisi ile İlişki: Bu proje, "Sağlık Teknolojileri" ve "Yapay Zeka ve Büyük Veri" kritik teknoloji alanlarına doğrudan katkı sağlamaktadır. 2030 Sanayi ve Teknoloji Stratejisi'nde öncelikli Ar-Ge konuları arasında yer alan "Kanser Teşhis ve Tedavi Teknolojileri" ve "Yapay Zeka Destekli İlaç Keşfi" başlıkları ile tam uyumludur. Projemizin başarılı olması durumunda, yerli yapay zeka ve biyoinformatik kapasitesinin güçlendirilmesi, uluslararası rekabetçi araştırma altyapısının oluşturulması ve yüksek etkili bilimsel yayınlar yoluyla ülkemizin stratejik sağlık teknolojileri ve yapay zeka alanlarında uluslararası düzeyde bilimsel rekabetçiliğine katkı sağlanacaktır.

### 1.2. Amaç ve Hedefler

Araştırma önerisinin amacı ve hedefleri açık, ölçülebilir, gerçekçi ve ulaşılabilir nitelikte olacak şekilde yazılır.

Projemizin temel amacı, geleneksel ilaç geliştirme yöntemlerinin başarısız olduğu MYC ve CTNNB1 düzensiz onkoproteinlerini hedefleyebilecek potansiyel ilaç adaylarını, makine öğrenmesi destekli ilaç yeniden konumlandırma stratejisi [11] kullanarak in silico olarak belirlemektir.

Somut Hedefler:

1. Yüksek doğruluklu makine öğrenmesi modellerinin geliştirilmesi: ChEMBL, PubChem ve BindingDB veri tabanlarından elde edilen biyoaktivite verileri (≥10000000 molekül) kullanılarak, Random Forest, Gradient Boosting Machines ve Graph Neural Network algoritmalarıyla MYC-MAX ve β-katenin-TCF4 protein-protein etkileşimlerini bozabilecek molekülleri tahmin edecek sınıflandırma modelleri geliştirmek (hedef performans: AUC ≥ 0.95).

2. Hit moleküllerin tanımlanması: PubChem BioAssay veritabanı taranarak geliştirilen modeller kullanılarak yeniden konumlandırılabilir, düşük toksisite puanına sahip potansiyel hit molekülleri belirlemek.

3. Hesaplamalı validasyon: Moleküler kenetlenme (AutoDock Vina, Glide), moleküler dinamik simülasyonları (100 ns) ve MM-GBSA serbest enerji hesaplamaları ile en yüksek skorlu hit moleküllerin (n≥5) bağlanma afiniteleri ve stabilitelerini doğrulayarak, ileri deneysel çalışmalara hazır önceliklendirilmiş aday listesi oluşturmak.

## 2. YÖNTEM

Araştırmada uygulanacak yöntem ve araştırma tekniklerinin, amaç ve hedeflere ulaşmaya ne düzeyde elverişli olduğu ilgili literatüre atıf yapılarak ortaya konulur.

Yöntem bölümünün; araştırma tasarımı, bağımlı ve bağımsız değişkenler, istatistiksel yöntemler vb. unsurları içermesi gerekir. Araştırma önerisinde herhangi bir ön çalışma veya fizibilite yapıldıysa bunların sunulması beklenir. Araştırma önerisinde sunulan yöntemlerin çalışma takvimi ile ilişkilendirilmesi gerekir.

Proje hedeflerine ulaşmak için uygulanacak analitik ve hesaplamalı yöntemler, beş temel iş paketi altında organize edilmiştir. Yöntemlerimiz, Sharma ve Arumugam tarafından Tankyrase inhibitörleri için uygulanan QSAR-ML iş akışından [8] ve Vignaux ve arkadaşları tarafından GSK3β için gerçekleştirilen Bayesian makine öğrenmesi tabanlı ilaç yeniden konumlandırmadan [11] ilham almaktadır.

**İP1 - Veri Toplama ve Ön İşleme** (1-2. Aylar): MYC-MAX ve β-katenin-TCF4 protein-molekül etkileşimlerini hedefleyen biyoaktivite verileri, ChEMBL, PubChem ve BindingDB veri tabanlarından toplanacaktır.

- PubChem BioAssay veritabanında MYC hedef proteini üzerinde aktif molekül içeren 98 deneyde https://www.ncbi.nlm.nih.gov/pcassay?db=pcassay&cmd=search&term=%22MYC%22[Gene%20Symbol]%20AND%20(pcassay_pccompound_active[filt])&loc=s_frm 850 aktif ve 16689 inaktif molekül mevcuttur.
- PubChem BioAssay veritabanında CTNNB1 hedef proteini üzerinde aktif molekül içeren 189 deneyde https://www.ncbi.nlm.nih.gov/pcassay?db=pcassay&cmd=search&term=CTNNB1[Gene%20Symbol]%20AND%20(pcassay_pccompound_active[filt])&loc=s_frm 1359 aktif ve 193002 inaktif molekül mevcuttur.

Sharma ve Arumugam, ChEMBL veri tabanından 1.100 Tankyrase inhibitörü verisi toplayarak başarılı bir makine öğrenmesi modeli geliştirmiştir [8]; benzer şekilde projemiz için de ön araştırmamıza istinaden her aday protein için en az 800-1.400 adet aktif/inaktif molekül verisi toplanması hedeflenmektedir. Toplanan veriler, RDKit (Python kimyainformatik kütüphanesi) kullanılarak standartlaştırılacak ve filtrenecektir. Moleküler yapılar, ECFP4 (parmak izi) gibi sayısal tanımlayıcılara dönüştürülecektir [2]. İlaç yeniden konumlandırma makine öğrenme modellerinde en büyük sorunlardan olan veri setindeki sınıf dengesizliği sorunu için öncelikle SMOTE tekniği denenecektir. Literatürdeki ilaç verisi makine öğrenme modellerinde tavsiye edilen sınıf dengesizliği çözümleri araştırılacaktır. Tüm veri seti, %80 eğitim ve %20 test setlerine ayrılacaktır. Her molekül için PubChem fingerprint öznitelik vektörü olarak kullanılacaktır.

**İP2 - Makine Öğrenmesi Modeli Geliştirme ve Optimizasyonu** (3-6. Aylar): Üç farklı makine öğrenmesi algoritması (Random Forest, Gradient Boosting Machines, Graph Neural Networks) ile sınıflandırma modelleri geliştirilecektir. Sharma ve Arumugam, Random Forest modelini sistematik hiperparametre optimizasyonu ile %98 AUC değerine çıkarmıştır [8]. Grid Search ve Randomized Search yöntemleri ile hiperparametre optimizasyonu gerçekleştirilecek, 10-katlı çapraz doğrulama ile model performansı değerlendirilecektir. Model performans metrikleri olarak AUC, hassasiyet, duyarlılık ve F1-skoru kullanılacaktır. Noor ve arkadaşları, Graph Neural Network modellerinin geleneksel yöntemlerden (%82 doğruluk) önemli ölçüde daha yüksek performans (%99 doğruluk) gösterdiğini kanıtlamıştır [7].

**İP3 - Sanal Tarama ve Hit Molekül Tanımlama** (7-8. Aylar): Geliştirilen makine öğrenmesi modeli, PubChem veritabanında aktivitesi mevcut ve düşük toksisite puanına sahip aday molekülleri taramak için uygulanacaktır. Model tarafından "aktif" olarak tahmin edilen moleküller (tahmin skoru ≥ 0.80), moleküler kenetlenme ile hesaplamalı validasyona tabi tutulacaktır. AutoDock Vina ve Glide yazılımları kullanılarak, hit moleküllerin MYC-MAX (PDB: 1NKP, 6G6K) ve β-katenin-TCF4 (PDB: 1G3J, 2GL7, 1JPW) protein-molekül etkileşim yüzeylerine kenetlenmesi simüle edilecektir [6]. Kenetlenme skorları ($\Delta G < -7.0$ kcal/mol) ve bağlanma modları analiz edilerek, en yüksek skorlu 20-30 hit molekül seçilecektir. MYC için fonksiyonel dimer (MYC-MAX) üzerinde tarama yapılacak ve 6G6K protein yapısı kullanılacaktır. CTNNB1 için 1JPW yapısı alınacak ve simülasyon TCF4 etkileşim arabirimi yakınında sınırlanacaktır. Ne MYC ne de CTNNB1 peptidlerine bağlandığı bilinen molekül yapısı ön araştırmalarımızda bulunamamıştır. AlphaFold protein dizisini girdi olarak aldığı ve apo formunda, yani hiçbir ligand, inhibitör, ilaç, metal iyonu veya DNA/RNA bağlanmamış bir protein modeli önerdiği

için molekül bağlanma modeli üretmesi mümkün değildir. Bu iş paketine gelindiğinde en son literatür taranarak eğer bağlandığı yapısal olarak gösterilen bir molekül bulunabilirse öncelikle o moleküller bu aşamada pozitif kontrol olarak denenecektir.

**İP4 - Moleküler Dinamik Simülasyonları ve Serbest Enerji Hesaplamaları** (9-11. Aylar): Seçilen hit moleküller için, GROMACS veya AMBER yazılımları kullanılarak 100 ns moleküler dinamik (MD) simülasyonları gerçekleştirilecektir. MD simülasyonları sırasında, protein-ligand kompleksinin stabilite analizi (RMSD, RMSF), hidrojen bağı oluşumu ve etkileşim enerjileri izlenecektir. Singh ve arkadaşlarının çalışmasında, uzun süreli MD simülasyonları c-Myc'in yapısal heterojenliğini göstermiş ve ensemble-bazlı yaklaşımın önemini vurgulamıştır [10]. MM-GBSA (Molecular Mechanics Generalized Born Surface Area) yöntemi ile bağlanma serbest enerjileri hesaplanacak [3]. En yüksek stabilite ve bağlanma afinitesi gösteren 5-10 molekül belirlenecektir (RMSD < 3 Å, $\Delta G < -25$ kcal/mol).

**İP5 - Makale Yazımı** (12-12. Aylar): Hesaplamalı validasyondan geçen hit moleküller, detaylı bir proje sonuç raporu halinde hazırlanacaktır. Rapor, her bir aday molekül için makine öğrenmesi tahmin skorları, moleküler kenetlenme sonuçları, MD simülasyon analizleri, MM-GBSA serbest enerji hesaplamaları ve farmakokinetik tahminleri (ADMET profilleri) içerecektir. Bir konferans bildirisi olarak rapor makaleye dönüştürülecektir.

## 3. PROJE YÖNETİMİ

### 3.1 Çalışma Takvimi

Araştırmada yer alacak başlıca faaliyetler, her bir faaliyetin hangi sürede gerçekleştirileceği, başarı ölçütü ve araştırmanın başarısına katkısı "Çalışma Takvimi" doldurularak sunulur.

**ÇALIŞMA TAKVİMİ (*)**

| Tarih Aralığı | Faaliyetler** | Kim(ler) Tarafından Gerçekleştirileceği | Başarı Ölçütü ve Araştırmanın Başarısına Katkısı*** |
|---|---|---|---|
| 1-2 ay | İP1: Veri Toplama ve Ön İşleme | Beyza Yörük<br>Doç.Dr.Tuğba Önal Süzek | ≥1000 molekül verisi toplanması ve temizlenmesi (20%) |
| 3-6 ay | İP2: ML Modeli Geliştirme | Beyza Yörük<br>Doç.Dr.Tuğba Önal Süzek | AUC ≥ 0.95 model performansı (25%) |
| 7-8 ay | İP3: Sanal Tarama | Beyza Yörük<br>Doç.Dr.Tuğba Önal Süzek | 20-30 hit molekül tanımlanması (20%) |
| 9-11 ay | İP4: MD Simülasyonları | Beyza Yörük<br>Doç.Dr.Tuğba Önal Süzek | 5-10 validasyonlu aday molekül (25%) |
| 12-12 ay | İP5: Raporlama | Beyza Yörük<br>Doç.Dr.Tuğba Önal Süzek | Makalenin Hazırlanması (10%) |

(*) Çizelgedeki satırlar ve sütunlar gerektiği kadar genişletilebilir ve çoğaltılabilir.
(**) Literatür taraması, sonuç raporu hazırlama aşamaları, araştırma sonuçlarının paylaşımı, ve malzeme alımı ayrı birer iş adımı olarak gösterilmemelidir.
(***) Başarı ölçütü, ölçülebilir ve izlenebilir nitelikte olacak şekilde nicel veya nitel ölçütlerle (ifade, sayı, yüzde, vb.) belirtilir. Bu sütundaki değerlerin toplamı 100 olmalıdır.

### 3.2 Risk Yönetimi

Araştırmanın başarısını olumsuz yönde etkileyebilecek riskler ve bu risklerle karşılaşıldığında araştırmanın başarıyla yürütülmesini sağlamak için alınacak tedbirler (B Planı) aşağıdaki Risk Yönetimi Tablosu'nda ifade edilir. B Plan(lar)ının uygulanması araştırmanın temel hedeflerinden sapmaya yol açmamalıdır. B Plan(lar)ına geçilmesi durumunda yöntem değişikliğine gidiliyor ise bu durum detaylandırılmalıdır.

**RİSK YÖNETİMİ TABLOSU***

| En Önemli Riskler | Alınacak Tedbirler (B Planı) |
|---|---|
| Over-fitting olması | Early stopping, Lasso regularization ve Ridge regularization gibi literatürde mevcut teknikler denenecektir. Upsampling teknikleri ile veri artırılması denenecektir. |
| Model performansının düşük olması | Ensemble yöntemler, derin öğrenme mimarileri, özellik mühendisliği denenecektir. PubChem fingerprint öznitelik vektörüne dayalı geleneksel makine öğrenme modelleri başarılı olamazsa moleküllerin resimleri derin modeli kurmak için |

| | |
|---|---|
| | kullanılacaktır. |

(*) Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

### 3.3.Araştırma Olanakları

Bu bölümde projenin yürütüleceği kurum ve kuruluşlarda var olan ve projede kullanılacak olan altyapı/ekipman (laboratuvar, araç, makine-teçhizat, vb.) olanakları belirtilir.

**ARAŞTIRMA OLANAKLARI TABLOSU (*)**

| **Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli** (Laboratuvar, Araç, Makine-Teçhizat, vb.) | **Projede Kullanım Amacı** |
|---|---|
| Süzek Lab Sunucuları | MD simülasyonları ve ML model eğitimi için hesaplama gücü |
| Üniversite Kütüphanesi | Basılı ve elektronik literatüre erişim için akademik veri tabanları |

**(*)** Tablodaki satırlar gerektiği kadar genişletilebilir ve çoğaltılabilir.

## 4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Araştırma önerisi kapsamındaki çalışmadan elde edilmesi öngörülen çıktılar amaçlarına göre belirlenen kategorilere ayrılarak belirtilir; ölçülebilir ve gerçekçi hedeflere dayandırılır.

| **Çıktı, Etki ve Kazanımlar** | **Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)** |
|---|---|
| **Bilimsel/Akademik Çıktılar** (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.) | Proje sonuç raporu bir makaleye dönüştürülerek akademik danışmanın çalışma grubu üyesi olduğu ML4NGP (Machine Learning for Non-Globular Proteins) COST Action https://ml4ngp.eu/ konferansında poster ya da sözlü sunum bildirisi olarak hazırlanacaktır. |
| **Ekonomik/Ticari/Sosyal Çıktılar** (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb. ) | |
| **Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar** (Ulusal/Uluslararası Yeni Proje vb.) | In-silico deneylerimiz sonucunda güvenilir hit adayı elde edilebilirse in-vitro çalışmalarının finansmanı için Tübitak 1002 ya da Tüseb projesi başvurusu yapılacaktır. |

## 5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

Sadece araştırma önerisinin değerlendirilmesine katkı sağlayabilecek bilgi/veri (grafik, tablo, vb.) eklenebilir.

| |
|---|
| Proje çıktılarının uluslararası görünürlüğünü artırmak amacıyla, akademik danışmanın aktif çalışma grubu üyesi olduğu ML4NGP (Machine Learning for Non-Globular Proteins) COST Action https://ml4ngp.eu/ konferansında poster ya da sözlü sunum olarak hazırlanacaktır. |

## 6. EKLER

### EK-1: KAYNAKLAR

[1] Cui, C., Zhou, X., Zhang, W., Qu, Y., & Ke, X. (2018). β-Katenin kanser tedavisi için ilaçlanabilir bir hedef mi? *Trends in Biochemical Sciences, 43*(8), 623-634. https://doi.org/10.1016/j.tibs.2018.06.003

[2] Díaz-Eufracio, B. I., & Medina-Franco, J. L. (2022). Protein-protein etkileşim inhibitörlerini tahmin etmek için makine öğrenmesi modelleri. *Molecules, 27*(22), 7986. https://doi.org/10.3390/molecules27227986

[3] Fatima, I., Khurshid, A., Javaid, N., Asghar, A., Rasool, N., Rana, M., Imran, M., & Hanif, M. (2024). Endometrial kanser için CTNNB1'i (β-katenin) hedefleyen küçük molekül inhibitörlerinin keşfi: 3D QSAR, ilaç benzerliği değerlendirmesi, ADMET tahminleri, moleküler kenetlenme ve simülasyon kullanımı. *Current Medicinal Chemistry*. https://doi.org/10.2174/0929867325072408261117154

[4] Karadkhelkar, N. M., Lin, M., Eubanks, L. M., & Janda, K. D. (2023). MYC onkogen ailesinin ilaçlanabilirliğinin gizemini çözmek. *Journal of the American Chemical Society, 145*(6), 3259-3269. https://doi.org/10.1021/jacs.2c12732

[5] Lehrich, B. M., Delgado, E. R., Yasaka, T. M., Liu, S., Cao, C., Liu, Y., Taheri, M. N., Guan, X., Koeppen, H., Singh, S., Meadows, V., Liu, J. J., Singh-Varma, A., Krutsenko, Y., Poddar, M., Hitchens, T. K., Foley, L. M., Liang, B., Rialdi, A.,... Monga, S. P. (2025). β-kateninin hassas hedeflenmesi hepatoselüler kanserlerde tümör yeniden programlanmasına ve bağışıklığa yol açar. *Nature Communications, 16*(1), 5009. https://doi.org/10.1038/s41467-025-60457-2

[6] Low, J. L., Du, W., Gocha, T., Oguz, G., Zhang, X., Chen, M. W., Masirevic, S., Yim, D. G. R., Tan, I. B. H., Ramasamy, A., Fan, H., & DasGupta, R. (2021). β-katenin-TCF4 etkileşimini hedefleyen küçük molekül inhibitörlerin moleküler kenetlenme destekli tanımlanması. *iScience, 24*(6), 102544. https://doi.org/10.1016/j.isci.2021.102544

[7] Noor, F., Junaid, M., Almalki, A. H., Almaghrabi, M., Ghazanfar, S., & Qamar, M. T. ul. (2024). İlaç keşfinde sanal taramayı hızlandırmak için derin öğrenme hattı. *Scientific Reports, 14*(1), 28321. https://doi.org/10.1038/s41598-024-79799-w

[8] Sharma, D., & Arumugam, S. (2025). Kolon adenokarsinomunda tankiraz inhibitörlerinin rasyonel tanımlanması için makine öğrenmesi destekli QSAR ve ağ farmakolojisi ile entegre hesaplamalı yaklaşım. *Computers in Biology and Medicine, 197*, 111068. https://doi.org/10.1016/j.compbiomed.2025.111068

[9] Singh, A., Kumar, A., Kumar, P., Nayak, N., Bhardwaj, T., Giri, R., & Garg, N. (2021). c-Myc-MAX heterodimerizasyonunu etkili bir şekilde engelleyen ve kanser hücrelerinde apoptozu indükleyen yeni bir inhibitör L755507. *Journal of Biological Chemistry, 297*(1), 100903. https://doi.org/10.1016/j.jbc.2021.100903

[10] Singh, A., Kumar, P., Sarvagalla, S., Bharadwaj, T., Nayak, N., Coumar, M. S., Giri, R., & Garg, N. (2022). "Sıcak nokta" hedefleme yoluyla tanımlanan yeni inhibitörler kullanılarak c-Myc'in fonksiyonel inhibisyonu. *The FASEB Journal, 36*(5).(https://doi.org/10.1096/fj.202101942R)

[11] Vignaux, P. A., Minerali, E., Foil, D. H., Puhl, A. C., & Ekins, S. (2020). GSK3β inhibitörlerinin keşfi için makine öğrenmesi. *ACS Omega, 5*(41), 26551-26561. https://doi.org/10.1021/acsomega.0c03302

[12] Yu, C., Niu, X., Jin, F., Liu, Z., Jin, C., & Lai, L. (2016). Yapı-tabanlı inhibitör tasarımı: içsel düzensiz protein c-Myc için. *Scientific Reports, 6*, 22298. https://doi.org/10.1038/srep22298

[13] Jiang, M., Amieva, R., Dey, S. K., Peng, L., Lewis, R. D., Che, A., Keogh, A., Zhou, H., Lebensohn, A. M., Rohatgi, R., Jackson, P. K., Bassik, M. C., & Wender, P. A. (2024). c-MYC transaktivasyon alanında ilaçlanabilir bir konformasyonel anahtar. *Nature Communications, 15*, 1852. https://doi.org/10.1038/s41467-024-45826-7

[14] Shionyu-Mitsuyama, C., Ohmori, S., Hirata, S., Ishida, H., & Shirai, T. (2025). IDRdecoder: içsel düzensiz bölgelere yönelik rasyonel ilaç keşfi için bir makine öğrenmesi yaklaşımı. *Frontiers in Bioinformatics, 5*, 1627836. https://doi.org/10.3389/fbinf.2025.1627836